Investigating Language-Agnostic Representations of Subject-Verb Agreement in a Language Model

Project Overview

Целью проекта является проверка существования универсального механизма subject-verb agreement в языковой модели и оценка того, насколько такие представления могут быть переносимыми между разными языками. Для анализа были выбраны итальянский и финский языки: оба языка реализуют схожее согласование подлежащего и глагола, однако их типологическая отдаленность с точки зрения морфологической структуры делает задачу более сложной и интересной. Основным методом исследования является activation patching, который позволяет заменять компоненты в нейронной сети и определять, какие из них каузально влияют на вывод модели. Дополнительно применялись методы linear steering и probing для верификации линейной извлекаемости признака числа и анализа его геометрической структуры в пространстве активаций.

В рамках проекта внимание сосредоточено именно на анализе слоев модели, без попыток детально восстанавливать отдельные головы или MLP, чтобы систематически изучить распределение информации о числе в residual stream. Для экспериментов использовалась модель Qwen 3 1.7B, небольшой размер который упрощает интерпретацию получаемых результатов на всех слоях и позволяет экономить вычислительные ресурсы.[1]

Data

Для проведения экспериментов были синтезированы параллельные датасеты на итальянском и финском языках. В них собраны предложения, представляющие собой контрастные пары, где подлежащее и глагол различаются по числу (пример на финском):

> ***taidemaalari*** *joka auttoi opettajia* ***on*** (**a painter** who helped teachers **is**…)
> ***taidemaalarit*** *jotka auttoivat opettajia* ***ovat*** (**painters** who helped teachers **are**…)

Структура предложений была намеренно усложнена введением аттракторов — существительных в придаточном предложении, число которых может не совпадать с числом подлежащего. Это позволяет проверить, насколько хорошо модель удерживает признак числа главного существительного на протяжении всей последовательности.

Каждый датасет был разделен на обучающую и тестовую выборку, содержащие 2800 и 600 примеров соответственно.

Layers Localization

Для задачи локализации слоев, в которых хранится информация о согласовании подлежащего и глагола, был использован метод активационного патчинга: из последнего токена[2] подлежащего извлекаются активации и вставляются на позицию глагола перед подсчетом финального выхода слоя. Для патчинга были взяты тестовые выборки, которые были разделены на “чистые” (clean) и “повреждённые” (corrupted) батчи: первая группа батчей

---

[1] Код, прилагаемый к этой работе, можно найти здесь: https://github.com/iwantsomemarzipan/investigating_sva_in_llm

[2] Выбор последнего токена для сбора активаций основывается на предположении о том, что именно в нём сконцентрирована информация о грамматическом числе. Соответственно, агрегация активаций (например, вычисление среднего) по всем токенам может нивелировать значимость сигнала, сделав целевой признак числа менее выраженным.

содержит активации, считающиеся “эталонными” для восстановления целевого глагола, вторая — активации для того же предложения, но с инвертированным числом подлежащего, вызывающим ошибочное грамматическое предсказание модели[3].

Патчинг для обоих языков был проведен в два этапа:

1. **Denoising**
   Это тест на достаточность: через слои запускаются повреждённые предложения, в которые вставляется активации субъекта из чистых предложений. Это позволяет определить, какие слои содержат достаточно информации для исправления грамматической ошибки.
2. **Noising**
   Это тест на необходимость: “шум” из повреждённого предложения патчится в чистое. Это показывает, на какие слои опирается модель: если зашумление ломает выход, значит, они важны в цепочке вычислений.

Для оценки результатов используется метрика logit difference, определяемая как разность между средними логитами для правильных и неправильных токенов глагола. Значения метрики усредняется по примерам в батче. Положительное значение соответствует предпочтению моделью варианта под влиянием вставленной активации. Для интерпретации эффекта патчинга используется нормализация от 0 до 1, где 0 означает отсутствие влияния патчинга на уверенность модели, а 1 — что вмешательство полностью сместило предсказание модели к уровню контрастного состояния. Иначе говоря, итоговое значение показывает, какую долю “исправления” (или, в случае noising, деградации) удалось воспроизвести с помощью патчинга на конкретном слое.

Результаты патчинга представлены на графиках ниже.

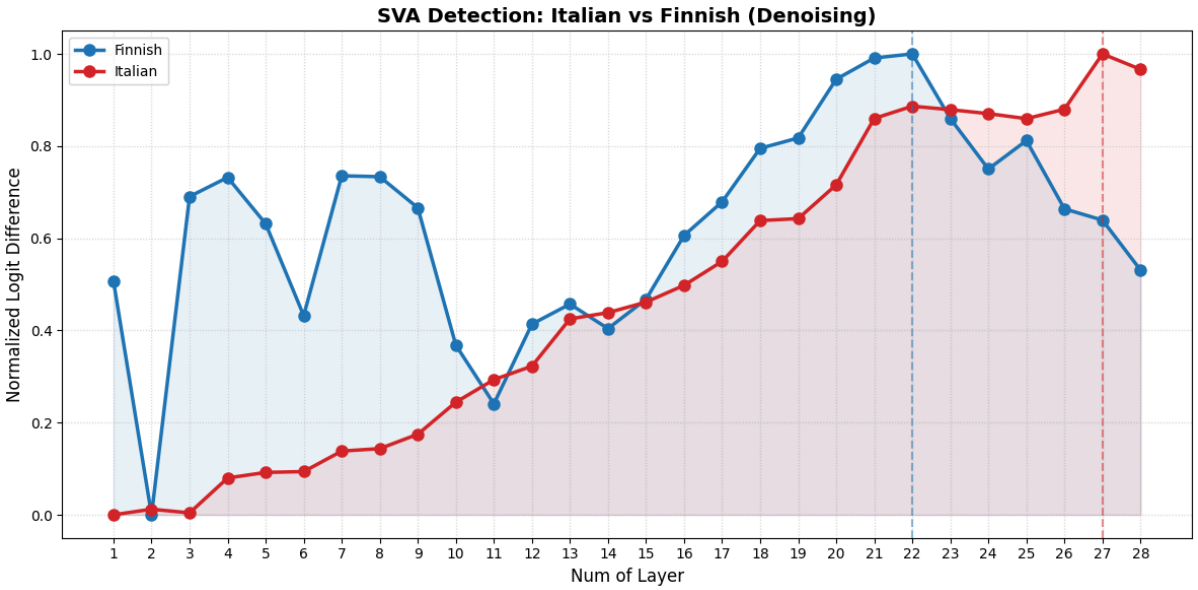

[3] Обе группы сбалансированы по единственному и множественному числа для избежания bias’a в данных и последующих результатах.

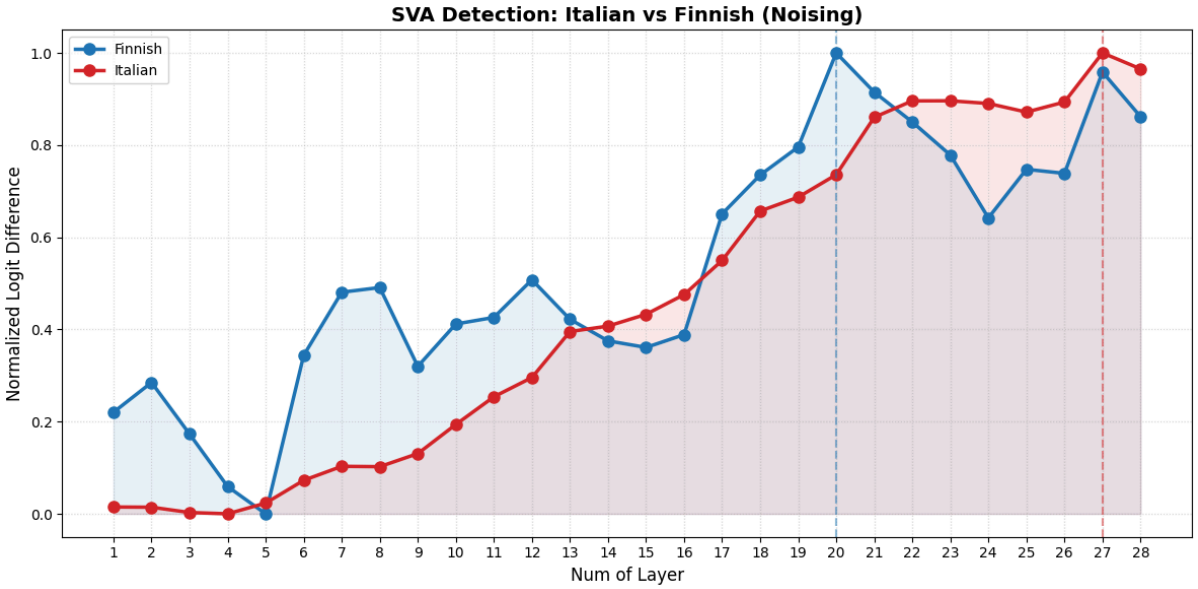

Можно заметить, что в обоих случаях для итальянского наблюдается плавный рост logit difference; при этом слои, оказавшиеся достаточными, также выделяются при noising. В то же время для финского характерны скачкообразные изменения на протяжении всех слоев, и не все слои демонстрируют согласованное поведение при denoising и noising. Тем не менее, для обоих языков сигнал о грамматическом числе в основном сконцентрирован в слоях 20–28. Последующий анализ был проведен именно в этом диапазоне.

Intralingual Probing-based Steering

Данный этап исследования направлен на проверку гипотезы о том, что информация о грамматическом числе подлежащего не просто присутствует в активациях, а представлена в линейно извлекаемом виде, пригодном для управляемого изменения (steering) предсказаний модели, с потенциальной целью кросс-языкового переноса этих направлений между языками.

На каждом из целевых слоев (20–28) из residual stream извлекаются активации на позиции последнего токена подлежащего. На основе этих данных обучается линейный классификатор (логистическая регрессия с L2-регуляризацией). Вектор весов обученного классификатора делится на его евклидову норму, что преобразует его в единичный вектор направления. В таком виде он интерпретируется как направление в пространстве активаций, кодирующее грамматическое число.

Далее проводится steering: к активации на последнем токене (позиции предсказания глагола) добавляется найденный вектор с коэффициентом, который управляет силой воздействия. Это позволяет целенаправленно смещать внутреннее представление модели в сторону одного из значений грамматического числа.

Эффект интервенции оценивается через изменение logit difference между правильными и неправильными формами глагола до и после вмешательства. Анализ проводится через grid search для различных слоев и значений коэффициента, что позволяет выявить область максимальной восприимчивости к вмешательству у модели. Кроме того, оценка результатов выполняется отдельно для примеров с единственным и множественным числом подлежащего, что необходимо для обнаружения возможной асимметрии: в некоторых случаях модели может быть значительно легче принять навязанный признак одного числа, чем другого.

По результатам grid search для обоих языков классификатор достигает полной accuracy на обучающих данных, что может свидетельствовать о линейной разделимости признака числа в пространстве активаций. Остальные данные представлены на графиках ниже.

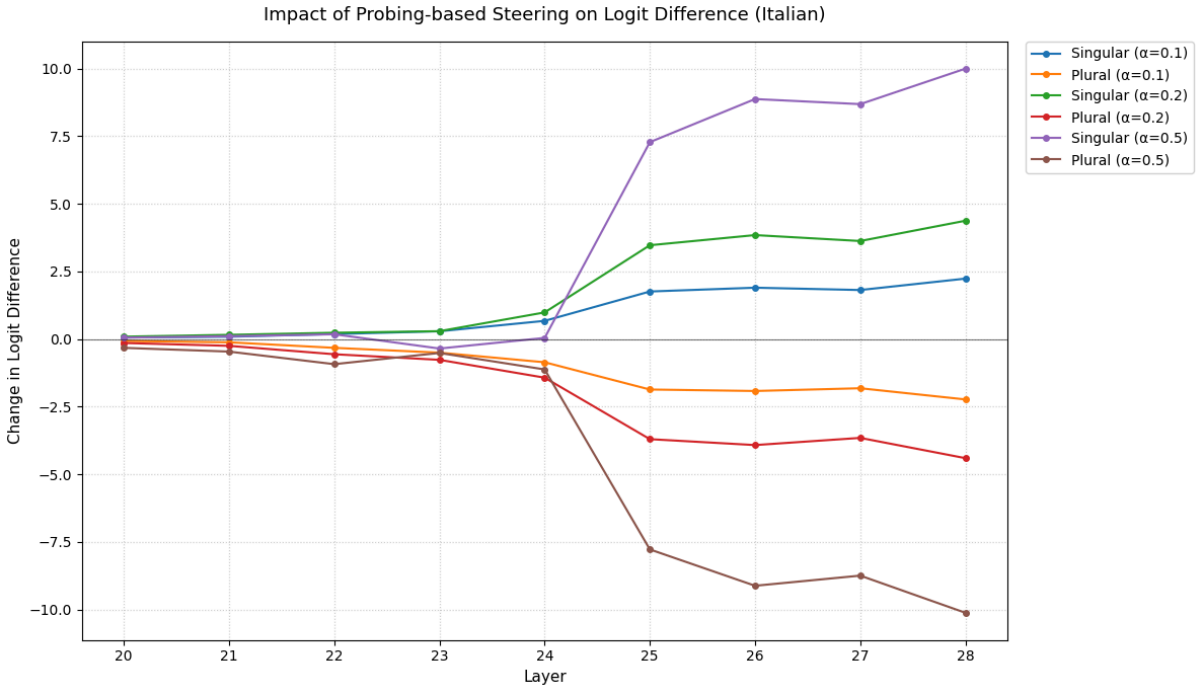

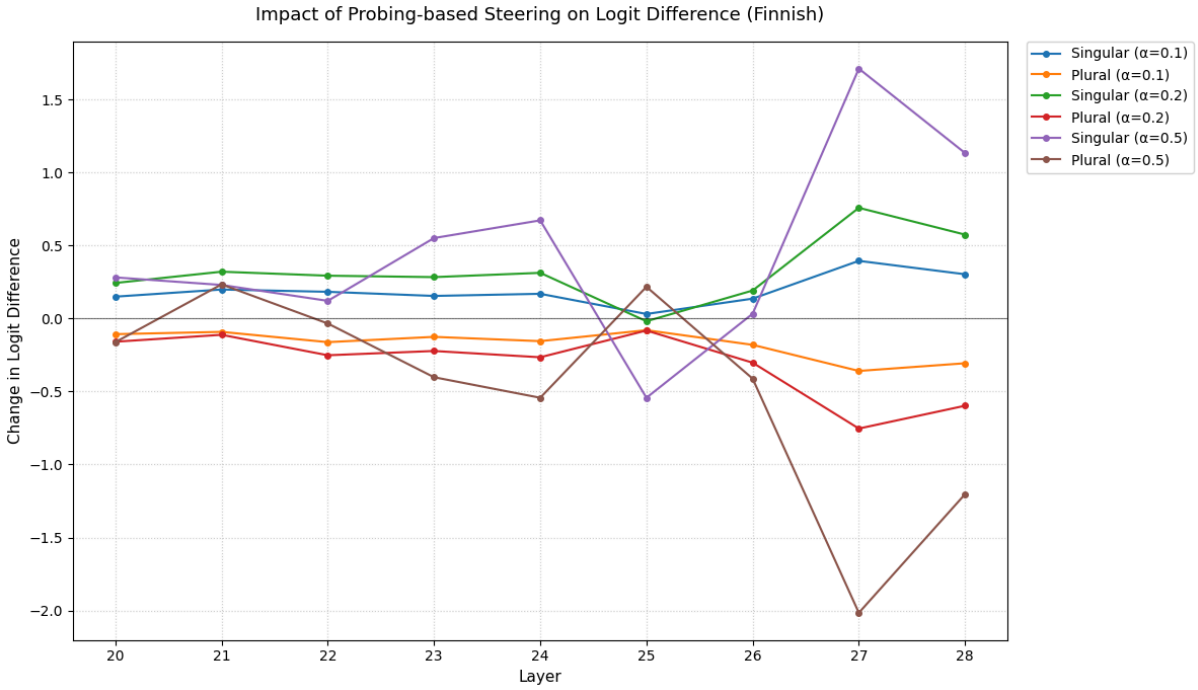

В случае с итальянским языком интервенция вектором направления стабильно увеличивает logit difference для единственного числа и зеркально снижает его для множественного по мере продвижения к поздним слоям. До 24-го слоя включительно эффект остается умеренным, а на слоях 23–24 наблюдается временная дестабилизация: при высоком коэффициенте 0.5 эффект может снижаться или даже менять знак (singular на 23-м слое). Максимальный эффект достигается в диапазоне 25–28 слоев, где изменение метрики превышает ±8–10 при коэффициенте 0.5. Это указывает на то, что в поздних слоях существует устойчивое линейное направление, вдоль которого признак числа может эффективно контролироваться.

Для финского языка влияние интервенции менее монотонно: динамика изменений в зависимости от слоя и коэффициента носит скачкообразный характер. Максимальный эффект зафиксирован на 27-м слое и составляет около 1.7–2.0, что в несколько раз слабее по сравнению с итальянским. На ранних этапах, например на 21-м слое, наблюдается аномальное поведение, когда при коэффициенте 0.5 воздействие на множественное число вместо ожидаемого снижения приводит к росту logit difference. Наиболее выраженная инверсия происходит на 25-м слое: при увеличении силы воздействия эффект становится отрицательным для единственного числа и положительным для множественного. В целом, для финского языка линейная интервенция оказывает менее стабильное и значительно более слабое влияние, что указывает на отсутствие устойчивого направления, вдоль которого признак числа мог бы последовательно контролироваться.

Для анализа геометрии представления признака числа был применён метод главных компонент (PCA) к активациям residual stream на 27-м слое, где steering показал наилучшие результаты.

На объединенном графике активаций обоих языков наблюдается доминирующее влияние языкового фактора.

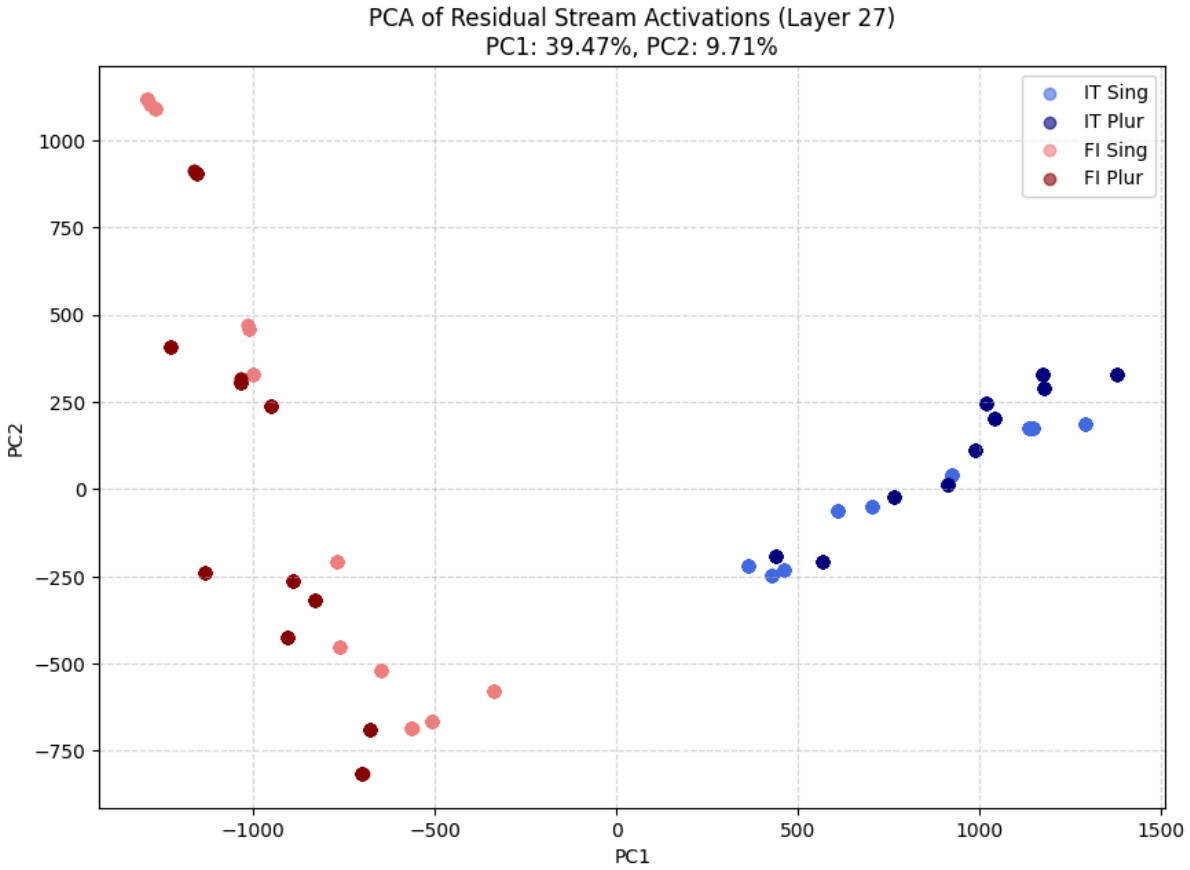

Первая главная компонента (PC1), объясняющая почти 40% дисперсии, полностью выделяет языковые кластеры. Кластер итальянского языка характеризуется высокой плотностью, в то время как финский значительно более разрежен.

Далее были построены графики для каждого языка по отдельности с разделением по числу.

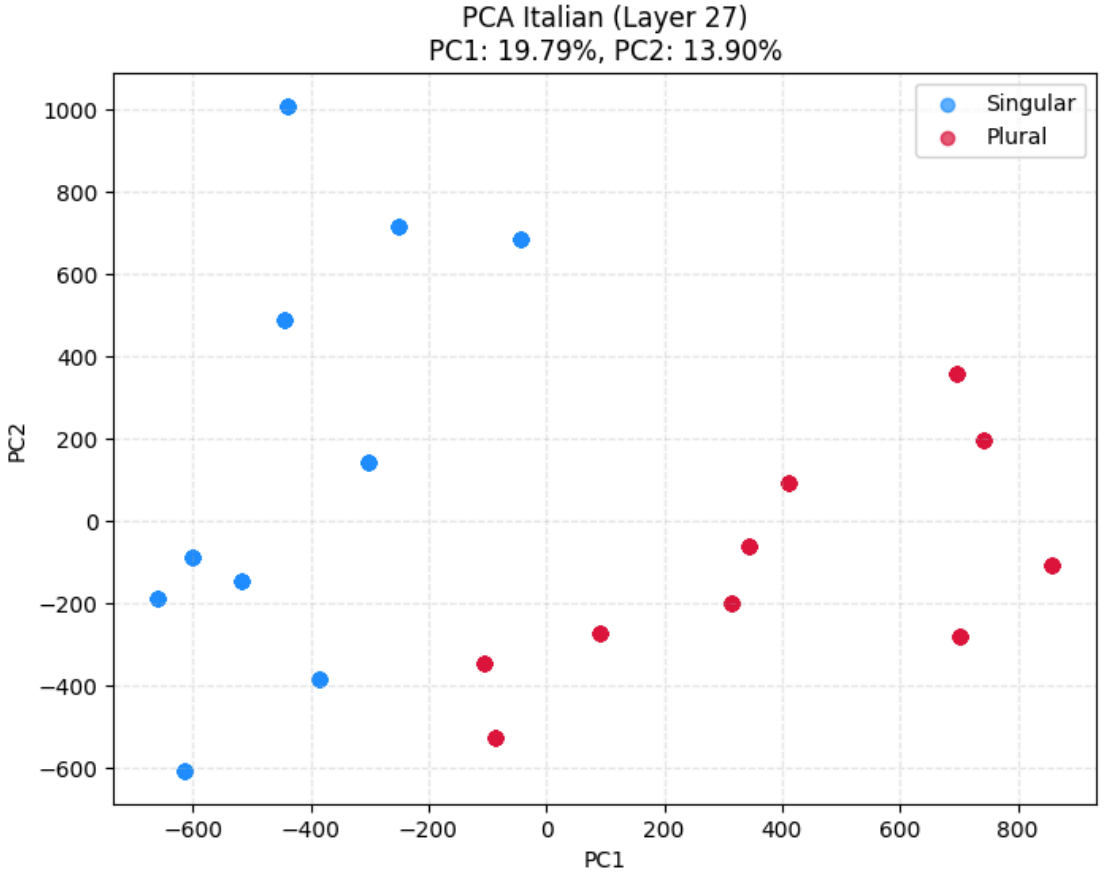
PCA Italian (Layer 27)
PC1: 19.79%, PC2: 13.90%
Singular
Plural
PC1
PC2
1000
800
600
400
200
0
−200
−400
−600
−600
−400
−200
0
200
400
600
800

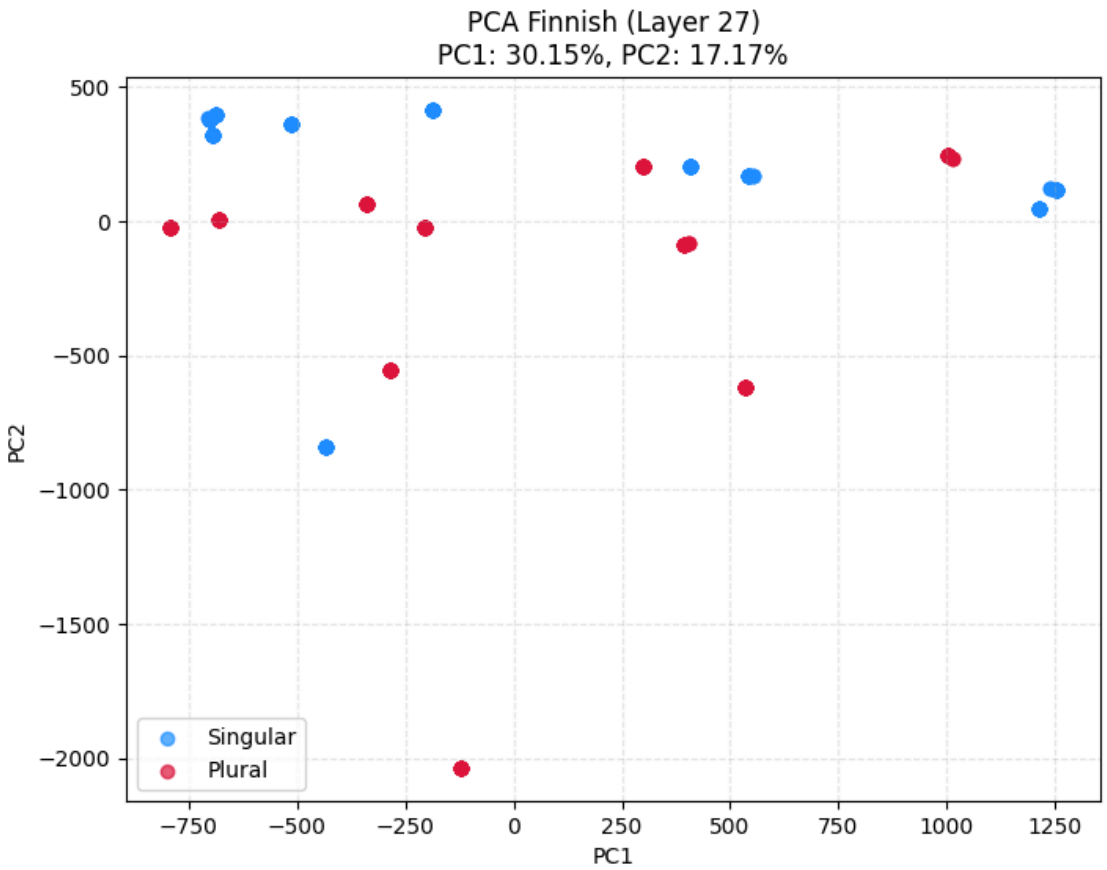
PCA Finnish (Layer 27)
PC1: 30.15%, PC2: 17.17%
Singular
Plural
PC1
PC2
500
0
−500
−1000
−1500
−2000
−750
−500
−250
0
250
500
750
1000
1250

Итальянский: точки распределены неплотно, однако наблюдается линейное разделение на области единственного и множественного числа.

Финский: несмотря на то, что компоненты объясняют около 47% всей дисперсии, что значительно выше, чем в итальянском, точки единственного и множественного числа оказались перемешанными перемешанными.

Таким образом, PCA подтверждает наблюдения из steering-эксперимента: в итальянском признаковое пространство числа более линейно разделимо, тогда как в финском оно более разрежено, что объясняет меньшую чувствительность модели к интервенции.

Для оценки схожести представления признака числа между итальянским и финским языками было рассчитано косинусное сходство между выученными векторами направления на каждом слое.

Layer	20	21	22	23	24	25	26	27	28
Cosine Similarity Score	0.154	0.135	0.171	0.137	0.127	0.149	0.089	0.068	0.045

Результаты показывают, что сходство невысокое на всех слоях, с постепенным снижением от верхних к нижним: на слое 20–24 значения находятся в диапазоне 0.12–0.17, а к слою 28 сходство падает до 0.045. Это указывает на то, что геометрия признака числа в активациях сильно различается между языками, и линейные направления, извлекаемые для одного языка, почти ортогональны направлениям другого языка.

Как упоминалось в начале раздела, предполагалось использовать извлеченные направления для cross-lingual steering, однако результаты показали, что переносимость маловероятна, поэтому этот подход был оставлен.

Cross-Lingual Probing

Далее был проведен кросс-языковой пробинг. Цель этого эксперимента — проверить, насколько линейные представления признака числа, извлеченные из активаций одного языка, обобщаются на другой язык. Другими словами, исследуется кросс-языковая переносимость обученных направлений из итальянского в финский и наоборот.

Эксперимент проводится следующим образом: для каждого слоя обученные классификаторы собирают активации на позициях подлежащего и проверяются как на “родном” языке (в качестве baseline), так и на другом языке.

Результаты представлены в таблице.

Layer	IT Native	FI Native	IT -> FI	FI -> IT
20	1.000	1.000	0.615	0.500
21	1.000	1.000	0.419	0.500
22	1.000	1.000	0.615	0.500
23	1.000	1.000	0.589	0.500

24	1.000	1.000	0.562	0.500
25	1.000	1.000	0.652	0.500
26	1.000	1.000	0.615	0.500
27	1.000	1.000	0.517	0.500
28	1.000	1.000	0.354	0.500

Точность классификатора, обученного на финском языке, при тестировании на итальянском, на всех слоях составляет ровно 0.500, что соответствует случайному угадыванию. Это указывает на отсутствие согласованности между разделяющими направлениями: гиперплоскость, построенная на финских активациях, не имеет проекции на вариацию, соответствующую грамматическому числу в итальянском. Классификатор, обученный на итальянском, демонстрирует результаты чуть выше случайных (за исключением слоя 21), однако к 28-му слою точность падает до 0.354. Это указывает на то, что по мере приближения к финальному предсказанию репрезентации становятся всё более language-specific, и общие грамматические абстракции вытесняются механизмами выбора токенов для конкретного языка.

Cross-Lingual Patching

Последним экспериментом является кросс-языковой патчинг. Цель — проверить, способна ли модель “считать” информацию о числе из активаций одного языка и использовать её для корректного предсказания в другом языке.

Эксперимент проводится следующим образом: из чистого батча языка-источника извлекаются активации на позиции последнего токена подлежащего, затем эти активации подставляются в повреждённый батч целевого языка на позицию предсказания глагола. Далее вычисляется logit difference между правильными и неправильными формами глагола до и после вмешательства. Значения нормируются относительно разницы между чистыми и повреждёнными батчами целевого языка, чтобы оценить относительный эффект патчинга.

Графики ниже иллюстрируют результаты патчинга.

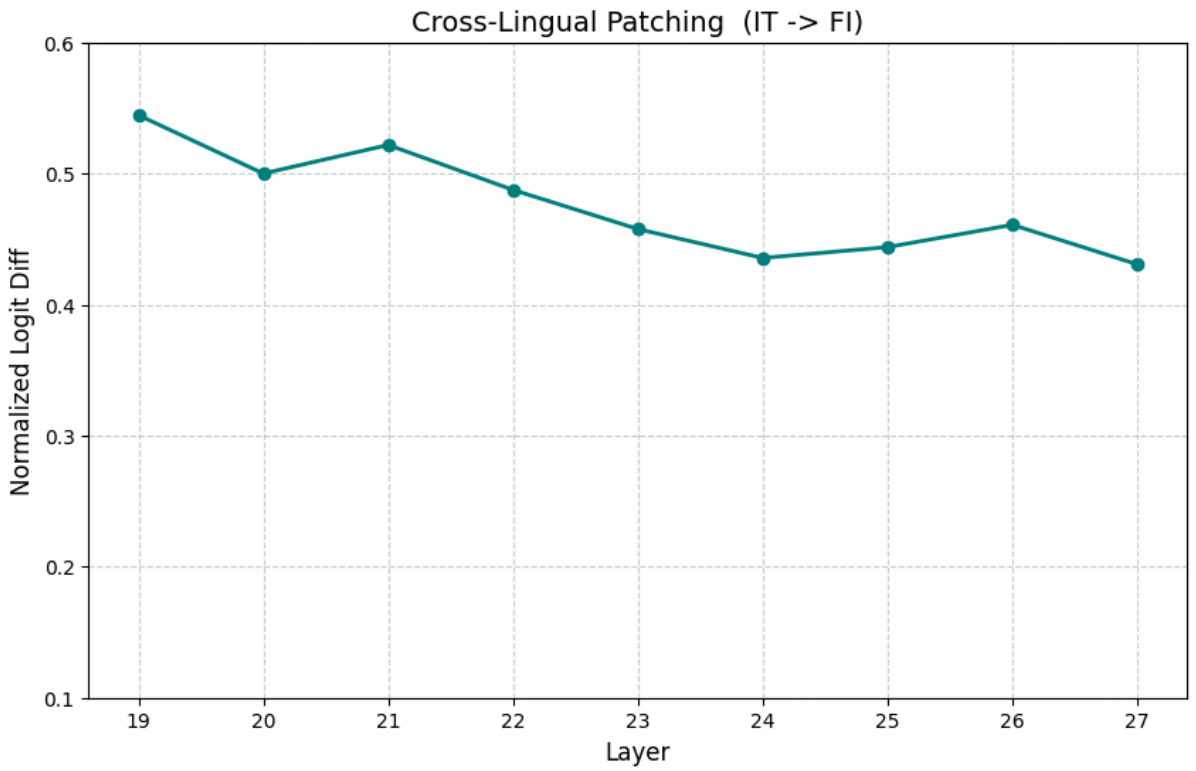

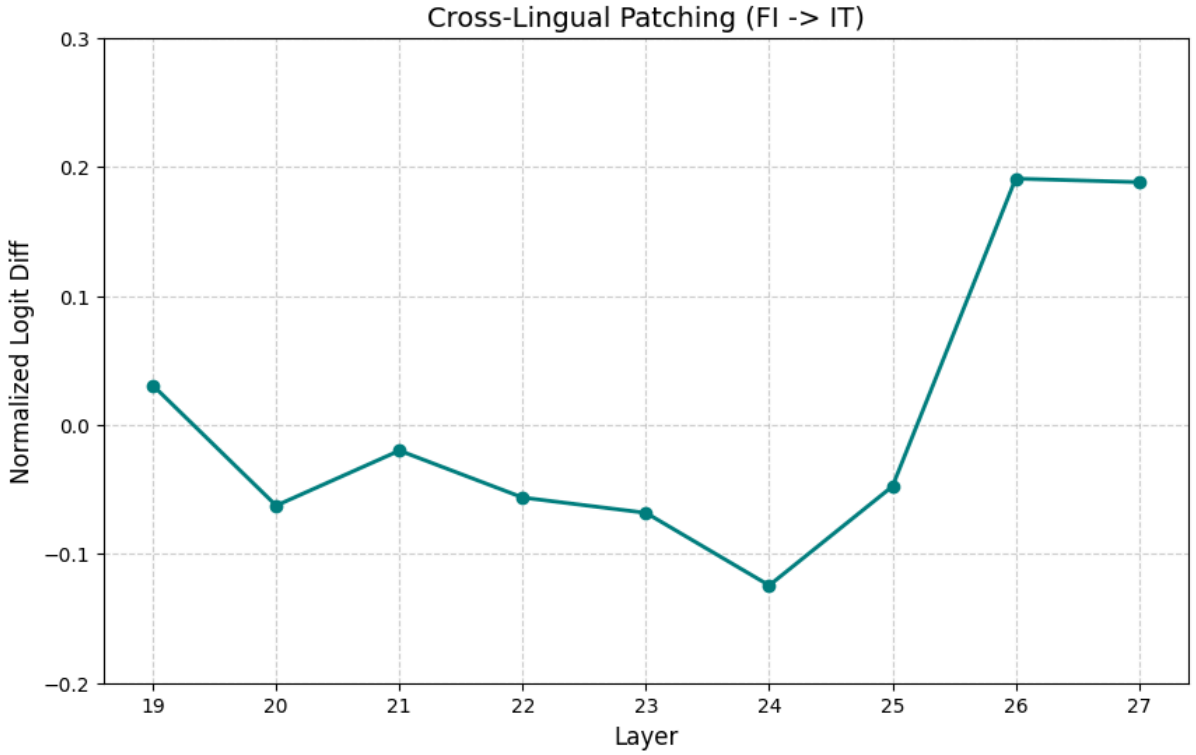

Перенос итальянского на финский: патчинг итальянских активаций повышает logit difference на всех слоях (0.43–0.54), что указывает на умеренную, но заметную переносимость грамматического сигнала числа из итальянского в финский. Эффект постепенно снижается от раннего к позднему слою.

Перенос финского на итальянский: патчинг финских активаций практически не улучшает logit difference на итальянском, значения колеблются около нуля и иногда отрицательны (-0.12–0.19). Это означает, что активации финского языка не содержат информации о числе, совместимой с

итальянской геометрией активаций, и в некоторых слоях вмешательство может даже ухудшать предсказания.

Conclusion

Все эксперименты показывают, что внутри каждого языка линейно извлекаемое представление грамматического числа действительно существует и сосредоточено в поздних слоях модели. Эксперименты с linear steering показывают, что эти репрезентации можно извлечь линейно: внутри языка классификаторы достигают высокой точности, и векторное вмешательство существенно изменяет logit difference. При этом переносимость направлений между языками крайне ограничена: итальянское направление частично влияет на финский, тогда как финское направление почти не работает на итальянском. Это согласуется с результатами кросс-языкового пробинга и патчинга.

Полученные результаты позволяют предположить, что итальянское подпространство в большей степени совместимо с гипотетическим универсальным представлением числа. Вероятно, в итальянском языке после обработки MLP-блоками информация о числе записывается в residual stream как относительно четкое и когерентное линейное направление. В случае с финским языком, напротив, можно предположить, что признак числа формируется непосредственно на уровне отдельных нейронов путем интеграции множества различных сигналов и не образует настолько же "явной" оси в общем потоке активаций. Это объясняет асимметрию при кросс-языковом переносе.